

MetaFlow Studio 代谢组学全流程分析软件

用户操作手册

版本号：V1.0

日期： 2026 年 5 月 11 日

目录

第一章 软件概述3

1.1 软件简介3

1.2 核心技术优势3

第二章 运行环境3

2.1 硬件环境3

2.2 软件环境4

2.3 浏览器要求4

第三章 核心功能与操作指南4

3.1 数据流导入与工程创建4

3.2 数据清洗与预处理5

3.3 无监督降维分析（PCA）6

3.4 有监督正交偏最小二乘判别分析（OPLS-DA）6

3.5 核心生物标志物挖掘（Biomarker Discovery）8

3.6 通路富集与生化机制网络9

第一章 软件概述

1.1 软件简介

MetaFlow Studio 代谢组学全流程分析软件（简称 MetaFlow Studio）面向生命科学、基础医学及临床研究领域，针对液相色谱-质谱联用（LC-MS）技术产生的高维、高噪声代谢组学原始数据，提供从数据清洗、质控对齐、统计建模到生物学解释的一站式分析方案。

1.2 核心技术优势

主要技术特点：

多模式数据合并机制：采用基于哈希（Hash）的数据隔离架构与三级去重策略，有效降低非靶向代谢组学中正负离子模式合并时的数据交叉干扰。

批次效应校正方法：内置基于随机森林的 SERRF 模型，用于追踪并校正仪器长时间运行引起的信号漂移。

标准化统计建模流程：支持 KNN 缺失值填充、PQN 概率商归一化及 Pareto 特征缩放，与 SIMCA 软件的数据处理逻辑保持一致。

通路富集分析策略：采用“官方 KEGG ID + 代谢物英文名”双重匹配机制，结合超几何分布检验完成通路富集，提升识别的准确率与灵敏度。

第二章 运行环境

2.1 硬件环境

为了保证 MetaFlow Studio 在处理大规模代谢组学数据（如数万个特征峰及复杂矩阵运算）时的响应速度，建议配置如下：

处理器（CPU）：Intel Core i5 或 AMD Ryzen 5 及以上系列，主频 2.5GHz 以上。

内存（RAM）：最低 8GB，建议配置 16GB 或以上（处理 MetDNA 多模式大文件时建议 16GB）。

硬盘（HDD/SSD）：可用空间 2GB 以上（用于存储本地 KEGG 数据库及缓存文件），建议使用固态硬盘（SSD）以提升数据加载速度。

显示器：分辨率建议 1920×1080 及以上，以获得最佳的可视化图表展示效果。

2.2 软件环境

操作系统：

Windows 10/11（64 位）系统。

或 macOS 10.15 及以上系统。

或 Linux（Ubuntu 20.04+, CentOS 7+）服务器环境。

支撑软件/运行库：

Python 环境：Python 3.9 及以上版本（需安装核心依赖包：Streamlit, Pandas, Scikit-learn, Plotly, NetworkX, Seaborn）。

网络要求：

软件初次同步 KEGG 官方通路数据库时需连接互联网；数据库同步完成后，核心统计分析功能支持离线运行。

2.3 浏览器要求

由于本软件采用响应式 Web 交互界面，建议使用以下浏览器以获得完整的动态渲染效果：

推荐使用：Google Chrome（谷歌浏览器）最新版。

备选使用：Microsoft Edge、Firefox（火狐浏览器）或 Safari。

注意：不建议使用 IE 浏览器或部分极速浏览器的兼容模式，以免导致 Plotly 交互式图表无法正常显示。

第三章 核心功能与操作指南

3.1 数据流导入与工程创建

用户启动系统后，首先进入左侧边栏的数据流控制台。系统支持三种主流仪器数据格式的自动解析：

MA 标准单表模式：适用于已预处理的标准丰度矩阵，软件可直接读取进行下游统计建模。

拟靶向 MRM 宽表模式：针对靶向定量数据，用户可自定义“特征后缀”（如“：面积”），系统将自动从冗余的下机表格中精准提取定量数据列并完成重命名。

MetDNA 原始宽表模式：针对非靶向多源数据。用户可同时上传多份不同离子模式的识别表格，系统将在底层进行特征查重与融合。



The screenshot shows a web interface titled "数据控制台" (Data Control Panel). It contains the following elements:

- 选择数据流模式 (Select Data Stream Mode):** Three radio button options:
 - 1. MA 标准单表 (自带分组) (MA Standard Single Table (Built-in Grouping))
 - 2. 拟靶向 MRM 宽表 (需后缀) (Simulated Targeted MRM Wide Table (Requires Suffix)) - This option is selected.
 - 3. MetDNA 原始宽表 (MetDNA Original Wide Table)
- 1. 上传 Sample Info (1. Upload Sample Info):**
 - Info表格 (.csv/.xlsx) [必填] (Info Table (.csv/.xlsx) [Required])
 - An "Upload" button with an upward arrow icon.
 - Text below the button: "200MB per file • CSV, XLSX"
- 2. 样本剔除 (黑名单) (2. Sample Exclusion (Blacklist)):**
 - A dropdown menu showing "No options to select" with a downward arrow icon.
- 3. 启用 SERRF 批次校正 (3. Enable SERRF Batch Correction):**
 - An unchecked checkbox.

图 1 数据上传与参数配置区截图

在上传数据矩阵前，用户需先上传包含样本名称与分组信息的“Sample Info”元数据表，并在下拉菜单中完成列名映射。若实验包含质控样本（QC），可在此步骤勾选“启用 SERRF 批次校正”，系统将在后台自动建立漂移校正模型。

3.2 数据清洗与预处理

数据加载完毕后，用户需在主界面的“分析参数配置”面板对全局数据进行预处理设定。这是保障后续模型准确性的关键步骤。

1. 缺失率过滤：用户可拖动滑块设定特征保留的阈值（推荐保留在 80% 以上样本中检出的有效特征）。
2. 缺失值填充：系统提供多种策略，包括模拟仪器检出限的“最小值的一半（Min）”填充，以及基于 K-近邻算法（KNN）的智能填充。
3. 特征缩放与归一化：为消除高丰度物质对模型的绝对统治力，系统推荐并默认使用 Pareto 缩放配合 PQN 归一化。该组合既能提升低丰度标志物的权重，又不会过度放大底层的仪器噪音。

分析参数配置

分组列

Group

数据预处理

缺失率过滤: 0.20

缺失值填充: KNN

样本归一化: PQN

特征缩放: Pareto

☒ Log2 对数转化

图 2 分析参数配置区数据预处理设置截图

3.3 无监督降维分析 (PCA)

完成预处理后,点击“执行分析”按钮,系统将极速运算并首先呈现主成分分析(PCA)结果。

PCA 作为一种无监督的模式识别方法,旨在观察所有样本在自然状态下的聚类趋势。图表中包含 95% 置信区间椭圆,用户可通过观察同组样本的聚集程度以及 QC 样本的分布集中度,直观评估实验数据的整体质量及是否存在显著的离群点(Outliers)。




图 3 PCA 散点图结果截图

3.4 有监督正交偏最小二乘判别分析 (OPLS-DA)

为了最大化区分不同生理/病理分组之间的差异,系统构建了 OPLS-DA 模型。该

模型通过正交信号校正（OSC）技术，将数据矩阵分解为与分组高度相关的预测主成分，以及与分组无关的正交噪音成分。

在此模块中，系统不仅提供清晰的 2D 得分图，还会自动计算模型的解释率（ R^2Y ）和交叉验证预测能力（ Q^2 ）。为了严防模型过拟合，系统默认执行 100 次置换检验（Permutation Test），并绘制包含回归截距的诊断图谱，确保挖掘出的差异特征具有绝对的统计学效力。




图 4 模型的解释率（ R^2Y ）、交叉验证预测能力（ Q^2 ）及 OPLS-DA 得分图截图




图 5 置换检验（Permutation Test）诊断图截图

3.5 核心生物标志物挖掘（Biomarker Discovery）

在确立了可靠的 OPLS-DA 模型后，系统提供多维度的数据可视化工具，协助研究人员精准锁定驱动组间分离的核心代谢物：

VIP 柱状图：提取模型中的变量投影重要性（VIP）得分，直观展示贡献度大于 1.0 的关键物质。

S-Plot 载荷图：结合特征的协方差与相关系数，用户可快速在“S”形曲线的左右两端锁定高置信度的标志物。

火山图（Volcano Plot）：融合经典统计学的 P-value 与变化倍数（Log2 Fold Change），以色彩编码（上调/下调）呈现全局差异代谢物的分布态势。




图 6 VIP 柱状图截图




图 7 S-Plot 载荷图截图




图 8 火山图截图

3.6 通路富集与生化机制网络

定位标志物后，系统将调用内置的最新 KEGG 官方数据库（支持人、小鼠、大鼠等背景）进行生物学意义翻译。

通路气泡图：基于实验实际检出特征的超几何分布检验，准确计算各通路的富集显著性（P-value）与富集因子。气泡大小与颜色深度直观反映通路的激活状态。

机制网络图（Network）：独家生成连接宏观代谢通路 with 微观差异代谢物的有向图谱。研究人员可通过该网络图，清晰洞察哪些具体的上调/下调物质共同引发了系统级别的代谢紊乱。




图 9 通路气泡图截图




图 10 机制网络图截图

第四章 结果导出与智能汇报

MetaFlow Studio 极大地简化了生信分析的后处理流程。在所有图表和数据列表的末端功能区，系统提供了极客级别的导出选项：

1. 交互式 HTML 报告导出：用户可一键将所有的分析参数、统计表格及动态交互图表打包为一个独立的 HTML 网页文件。该文件脱离原始软件环境后依然支持数据的缩放、悬停查看等交互操作，极大地方便了团队内部的汇报与展示。

2. AI 辅助撰稿 Prompt 生成：系统能够自动提取关键标志物与核心代谢通路信息，组装成符合大语言模型逻辑的 Markdown 提示词。用户可借此无缝对接 AI 工具，快速生成符合 SCI 论文规范的结果章节初稿。



图 11 离线报告下载和 AI 提示词文件下载按钮界面截图